

LAPORAN TEKNIS UJIAN AKHIR SEMESTER PEMBELAJARAN MESIN

**KLASIFIKASI KUALITAS UDARA (AIR QUALITY CLASSIFICATION)
BERDASARKAN PARAMETER METEOROLOGI DAN LINGKUNGAN
MENGUNAKAN MACHINE LEARNING DAN STREAMLIT
DASHBOARD**

Dosen Pengampu:
Abu Salam, M.Kom



Disusun oleh:
Sabrina Angel Lilga Putri Maharani – A11.2024.15596

**PROGRAM STUDI TEKNIK INFORMATIKA
UNIVERSITAS DIAN NUSWANTORO SEMARANG
TAHUN 2025/2026**

DAFTAR ISI

DAFTAR ISI.....	2
DAFTAR TABEL.....	4
DAFTAR GAMBAR.....	5
BAB I	
BAB I PENDAHULUAN.....	6
1.1 Latar Belakang.....	6
1.2 Mengapa Machine Learning Diperlukan?.....	6
1.3 Definisi Learning Task.....	6
1.4 Tujuan Bisnis / Analitik.....	7
1.5 Metrik Kesuksesan.....	7
1.6 Ringkasan Dataset.....	7
BAB II	
BAB II RUMUSAN MASALAH DAN TUJUAN.....	8
2.1 Identifikasi Masalah.....	8
2.2 Tujuan Proyek.....	8
2.2.1 Tujuan Utama.....	8
2.2.2 Tujuan Komparatif.....	8
2.2.3 Tujuan Analitik.....	8
2.2.4 Tujuan Deployment.....	9
2.3 Hipotesis Awal.....	9
BAB III	
BAB III DATASET DAN EXPLORATORY DATA ANALYSIS.....	10
3.1 Feature Selection Awal.....	10
3.2 Deskripsi Fitur.....	10
3.3 Data Quality Check.....	10
3.4 Data Consistency Check — Temuan Penting.....	11
3.5 Distribusi Kelas Target.....	12
3.6 Analisis Univariat, Outlier, dan Korelasi.....	12
3.7 Fitur vs Target — Pola per Kelas.....	13
3.8 Ringkasan Insight EDA.....	13
BAB IV	
BAB IV METODOLOGI DAN PIPELINE MACHINE LEARNING.....	14
4.1 Ringkasan Preprocessing.....	14
4.2 Strategi Data Splitting.....	14
4.3 Gambaran Umum Pipeline End-to-End.....	15
BAB V	
BAB V PEMODELAN, TUNING, DAN VALIDASI STATISTIK.....	16
5.1 Baseline Model (Hyperparameter Default).....	16
5.2 Hyperparameter Tuning (GridSearchCV).....	16
5.3 Model Selection: 10-Fold Stratified Cross Validation dan Paired T-Test.....	17

5.4 Karakteristik Kedua Algoritma.....	17
BAB VI	
BAB VI HASIL EVALUASI DAN INTERPRETASI MODEL.....	18
6.1 Evaluasi Akhir pada Test Set (Data yang Belum Pernah Dilihat).....	18
6.2 Classification Report per Kelas.....	18
6.3 Interpretasi Model: Feature Importance dan SHAP.....	20
6.4 Insight Bisnis.....	21
6.5 Analisis Overfitting.....	21
BAB VII	
BAB VII DEPLOYMENT STREAMLIT DASHBOARD.....	23
7.1 Platform dan Alasan Pemilihan.....	23
7.2 Struktur Halaman Aplikasi.....	23
Gambar 7 Halaman Beranda.....	24
Gambar 8 Halaman Dashboard.....	24
Gambar 9 Halaman Model Demo.....	25
Gambar 10 Halaman Evaluasi Model.....	25
Gambar 11 Halaman Interpretasi dan Insight.....	26
Gambar 12 Halaman Dokumentasi.....	26
7.3 Alur Inference: Input → Model → Output.....	27
7.4 Penanganan File pada Deployment.....	27
BAB VIII	
BAB VIII DOKUMENTASI REPOSITORY, KESIMPULAN, DAN REKOMENDASI.....	28
8.1 Struktur Repository GitHub.....	28
8.2 Kesimpulan.....	29
8.3 Rekomendasi Pengembangan Selanjutnya.....	29
DAFTAR PUSTAKA.....	31

DAFTAR TABEL

Tabel 1 Informasi Dataset	7
Tabel 2 Deskripsi Fitur Dataset	10
Tabel 3 Ringkasan Data Quality & Consistency Check	11
Tabel 4 Distribusi Kelas Target (Air Quality)	12
Tabel 5 Ringkasan Preprocessing	14
Tabel 6 Strategi Data Splitting (Train/Val/Test)	15
Tabel 7 Hasil Baseline Model (Validation Set)	16
Tabel 8 Grid Hyperparameter dan Hasil Tuning	16
Tabel 9 Hasil 10-Fold Cross Validation dan Paired T-Test	17
Tabel 10 Karakteristik Logistic Regression dan Random Forest	17
Tabel 11 Perbandingan Ringkasan Performa Akhir	18
Tabel 12 Classification Report Final — Random Forest (Test Set)	18
Tabel 13 Classification Report Final — Logistic Regression (Test Set)	19
Tabel 14 Feature Importance & SHAP Ranking	21
Tabel 15 Halaman pada Aplikasi Streamlit	23
Tabel 16 Struktur Repository GitHub	28

DAFTAR GAMBAR

Gambar 1 Temuan Inkonsistensi Data Humidity > 100%	11
Gambar 2 Distribusi Kelas Air Quality	12
Gambar 3 Diagram Alur Pipeline Machine Learning	15
Gambar 4 Confusion Matrix — Final Random Forest (Test Set)	19
Gambar 5 Feature Importance — Random Forest	20
Gambar 6 SHAP Summary Plot per Kelas	20
Gambar 7 Halaman Beranda	24
Gambar 8 Halaman Dashboard.....	24
Gambar 9 Halaman Model Demo	25
Gambar 10 Halaman Evaluasi Model	25
Gambar 11 Halaman Interpretasi dan Insight	26
Gambar 12 Halaman Dokumentasi	26
Gambar 13 Diagram Alur Interface	27

BAB I

BAB I PENDAHULUAN

1.1 Latar Belakang

Pencemaran udara merupakan permasalahan lingkungan yang terus meningkat di berbagai kawasan perkotaan dan industri. Pemantauan kualitas udara secara konvensional umumnya bergantung pada sensor polutan kimia secara langsung, seperti PM2.5, PM10, NO2, SO2, dan CO. Sensor-sensor tersebut memiliki biaya pengadaan dan perawatan yang tinggi, sehingga sulit diterapkan secara masif, khususnya di wilayah dengan keterbatasan infrastruktur.

Proyek Capstone ini mengeksplorasi pendekatan alternatif: apakah kategori kualitas udara dapat diprediksi hanya menggunakan parameter meteorologi dan kontekstual — Temperature, Humidity, Proximity_to_Industrial_Areas, dan Population_Density — tanpa melibatkan data polutan kimia sama sekali? Pendekatan ini realistis dan bermanfaat secara praktis, karena stasiun cuaca jauh lebih umum dan lebih murah untuk dipasang dibanding sensor polutan khusus. Model yang mampu mengestimasi kategori kualitas udara hanya dari data cuaca dan konteks demografis dapat menjadi proxy peringatan dini berbiaya rendah di wilayah tanpa infrastruktur pemantauan polutan yang memadai.

1.2 Mengapa Machine Learning Diperlukan?

Pendekatan rule-based konvensional tidak mampu menangkap interaksi non-linear antar berbagai faktor meteorologi secara simultan — misalnya, dampak suhu tinggi terhadap kualitas udara dapat berbeda tergantung tingkat kelembapan dan kedekatan wilayah dengan kawasan industri. Machine Learning mampu mempelajari pola tersembunyi dari data historis secara otomatis, termasuk interaksi non-linear antar fitur, serta memberikan skor kepentingan fitur (feature importance dan SHAP) yang memberikan wawasan mengenai faktor paling dominan yang memengaruhi kualitas udara.

1.3 Definisi Learning Task

Permasalahan ini termasuk kategori Supervised Learning, klasifikasi multi-kelas. Target adalah variabel Air Quality dengan empat kategori: Good, Moderate, Poor, dan Hazardous. Fitur input dibatasi hanya pada empat variabel non-polutan: Temperature, Humidity, Proximity_to_Industrial_Areas, dan Population_Density. Lima fitur polutan kimia

(PM2.5, PM10, NO2, SO2, CO) sengaja dihilangkan dari dataset asli karena label kualitas udara diturunkan langsung dari nilai-nilai tersebut — jika tetap digunakan sebagai fitur input, akan menyebabkan data leakage yang parah, di mana model pada dasarnya “diberi tahu” jawabannya secara langsung.

1.4 Tujuan Bisnis / Analitik

Tujuan proyek ini adalah membangun model klasifikasi multi-kelas yang memprediksi kategori Air Quality menggunakan fitur meteorologi dan kontekstual, kemudian mengemasnya ke dalam dashboard interaktif yang dapat digunakan oleh pemangku kepentingan non-teknis, seperti pemerintah daerah atau lembaga lingkungan, untuk mengeksplorasi prediksi dan wawasan yang dihasilkan model.

1.5 Metrik Kesuksesan

Karena kelas target bersifat tidak seimbang (dijelaskan pada BAB III), akurasi keseluruhan saja tidak cukup untuk mengukur keberhasilan model. Proyek ini menargetkan model dengan macro-averaged F1-Score di atas 0,80 dan ROC-AUC di atas 0,90, dengan perhatian khusus pada recall kelas minoritas Hazardous — karena kegagalan mendeteksi kualitas udara berbahaya memiliki konsekuensi dunia nyata yang jauh lebih besar dibandingkan false alarm.

1.6 Ringkasan Dataset

Atribut	Detail
Nama Dataset	Air Quality and Pollution Assessment
Sumber	Kaggle — oleh Mujtaba Matin
Ukuran	5.000 baris x 10 kolom (data mentah)
Fitur mentah	Temperature, Humidity, PM2.5, PM10, NO2, SO2, CO, Proximity_to_Industrial_Areas, Population_Density
Target	Air Quality — 4 kategori (Good, Moderate, Poor, Hazardous)

Tabel 1 Informasi Dataset

BAB II

BAB II RUMUSAN MASALAH DAN TUJUAN

2.1 Identifikasi Masalah

- Bagaimana membangun model Machine Learning yang mampu mengklasifikasikan kategori kualitas udara secara akurat hanya menggunakan parameter meteorologi dan lingkungan, tanpa data polutan kimia?
- Algoritma klasifikasi mana yang memberikan performa terbaik — Logistic Regression atau Random Forest — setelah melalui proses hyperparameter tuning?
- Apakah perbedaan performa antar model bersifat signifikan secara statistik, atau hanya kebetulan akibat pembagian data?
- Faktor meteorologi atau lingkungan apa yang paling dominan memengaruhi klasifikasi kualitas udara ketika data polutan tidak tersedia?
- Bagaimana menyajikan solusi Machine Learning ini agar dapat digunakan oleh pemangku kepentingan non-teknis secara interaktif?

2.2 Tujuan Proyek

2.2.1 Tujuan Utama

Membangun model Machine Learning berbasis klasifikasi multi-kelas yang mampu memprediksi kategori kualitas udara (Good, Moderate, Poor, Hazardous) berdasarkan parameter meteorologi dan lingkungan non-polutan.

2.2.2 Tujuan Komparatif

Membandingkan performa Logistic Regression dan Random Forest, baik sebelum maupun sesudah hyperparameter tuning, menggunakan validation set, 10-Fold Stratified Cross Validation, dan Paired T-Test.

2.2.3 Tujuan Analitik

Mengidentifikasi fitur meteorologi/lingkungan yang paling berpengaruh terhadap prediksi kualitas udara menggunakan feature importance Random Forest dan analisis SHAP (SHapley Additive exPlanations).

2.2.4 Tujuan Deployment

Mengemas model terbaik ke dalam aplikasi web interaktif berbasis Streamlit yang mencakup dashboard EDA, demo prediksi real-time, evaluasi model, interpretasi hasil, dan dokumentasi — sehingga dapat diakses oleh pengguna non-teknis.

2.3 Hipotesis Awal

- Model Random Forest diperkirakan menghasilkan performa yang lebih baik dibandingkan Logistic Regression, karena kemampuannya menangkap hubungan non-linear antar fitur meteorologi tanpa memerlukan asumsi linearitas.
- Perbedaan performa antara Random Forest dan Logistic Regression diperkirakan signifikan secara statistik berdasarkan Paired T-Test dengan tingkat signifikansi $p < 0,05$.
- Fitur Proximity_to_Industrial_Areas dan Temperature diperkirakan menjadi dua faktor paling dominan dalam menentukan kategori kualitas udara.

BAB III

BAB III DATASET DAN EXPLORATORY DATA ANALYSIS

3.1 Feature Selection Awal

Sebelum eksplorasi, lima kolom polutan kimia (PM2.5, PM10, NO2, SO2, CO) dihapus dari dataset mentah. Ini merupakan keputusan feature selection yang disengaja, bukan kelalaian — konsentrasi polutan digunakan secara langsung untuk menurunkan label Air Quality pada dataset asli, sehingga jika tetap disertakan akan menyebabkan data leakage yang parah. Dengan membatasi fitur hanya pada variabel meteorologi dan kontekstual (Temperature, Humidity, Proximity_to_Industrial_Areas, Population_Density), model yang dihasilkan mencerminkan permasalahan yang lebih realistis dan lebih sulit: memprediksi kualitas udara tanpa sensor polutan.

3.2 Deskripsi Fitur

Fitur	Tipe Data	Keterangan	Peran
Temperature	Float	Suhu udara rata-rata	Input
Humidity	Float	Kelembapan relatif (%)	Input
Proximity_to_Industrial_Areas	Float	Jarak wilayah terhadap kawasan industri terdekat	Input
Population_Density	Integer	Kepadatan penduduk wilayah	Input
PM2.5, PM10, NO2, SO2, CO	Float	Konsentrasi polutan kimia — dihapus untuk mencegah data leakage	Dihapus
Air Quality	Kategorikal	Label target: Good / Moderate / Poor / Hazardous	Target


Tabel 2 Deskripsi Fitur Dataset

3.3 Data Quality Check

Pengecekan tipe data, missing value, dan baris duplikat menunjukkan dataset memiliki 5.000 baris tanpa missing value dan tanpa baris duplikat sama sekali, sehingga tidak diperlukan imputasi maupun penghapusan baris pada tahap ini.

3.4 Data Consistency Check — Temuan Penting

Selain pengecekan missing value dan duplikat, dilakukan juga pengecekan konsistensi nilai secara fisik/logis. Secara teori, kelembapan relatif (Humidity) harus berada pada rentang 0–100%. Pengecekan ini mengungkap sebuah inkonsistensi yang tidak terlihat dari pengecekan standar:



Gambar 1 Temuan Inkonsistensi Data Humidity > 100%

Temuan	Detail
Jumlah baris bermasalah	195 baris ($\approx 3,9\%$ dari total data)
Rentang nilai sebelum perbaikan	Humidity mencapai hingga 128,1% — melebihi batas fisik maksimum 100%
Kemungkinan penyebab	Noise sensor atau artefak kalibrasi, bukan sinyal yang bermakna
Keputusan	Nilai Humidity di-cap (dibatasi) pada maksimum 100%, bukan menghapus baris — sehingga seluruh 5.000 baris tetap dipertahankan tanpa membuang data fitur lain yang valid

Tabel 3 Ringkasan Data Quality & Consistency Check


Temuan ini penting untuk ditunjukkan karena mencerminkan proses EDA yang teliti — tidak berhenti pada pengecekan missing value/duplikat standar, tetapi juga memvalidasi apakah nilai suatu fitur masuk akal secara domain (domain plausibility check).

3.5 Distribusi Kelas Target

Kelas Good dan Moderate mendominasi dataset (40% dan 30%), sementara kelas Hazardous hanya memiliki 500 sampel (10%). Ketidakseimbangan ini menjadi pertimbangan utama dalam evaluasi model — akurasi keseluruhan saja berpotensi menyesatkan, sehingga evaluasi bergantung pada Stratified K-Fold (BAB V) dan classification report per kelas (BAB VI) untuk memastikan performa pada kelas minoritas Hazardous tetap terlihat jelas.

Kelas	Jumlah	Persentase
Good	2.000	40,0%
Moderate	1.500	30,0%
Poor	1.000	20,0%
Hazardous	500	10,0%

Tabel 4 Distribusi Kelas Target (Air Quality)



Gambar 2 Distribusi Kelas Air Quality

3.6 Analisis Univariat, Outlier, dan Korelasi

Analisis distribusi menunjukkan Temperature dan Humidity berbentuk mendekati normal (sedikit right-skewed), sedangkan Proximity_to_Industrial_Areas dan Population_Density lebih menyebar. Tidak ditemukan skewness ekstrem, sehingga tidak diperlukan transformasi khusus seperti log-transform.

Boxplot menunjukkan outlier ringan pada Temperature dan Humidity, namun jumlahnya sedikit dan merepresentasikan kondisi cuaca ekstrem yang plausible, bukan kesalahan input data — sehingga outlier tersebut dipertahankan (tidak dihapus), karena kondisi cuaca ekstrem relevan untuk memprediksi kelas Hazardous.

Heatmap korelasi antar fitur menunjukkan korelasi rendah hingga sedang (tidak ada yang mendekati ± 1), sehingga tidak ada masalah multikolinearitas serius. Hal ini menguntungkan khususnya untuk Logistic Regression yang sensitif terhadap fitur yang saling berkorelasi tinggi.

3.7 Fitur vs Target — Pola per Kelas

Analisis boxplot fitur terhadap kelas target menunjukkan sampel Hazardous dan Poor cenderung memiliki Proximity_to_Industrial_Areas yang lebih rendah (lebih dekat ke kawasan industri) dan Temperature yang lebih tinggi dibandingkan kelas Good. Pola ini kemudian dikonfirmasi oleh hasil SHAP pada BAB VI, di mana kedua fitur tersebut terbukti menjadi prediktor paling penting.

3.8 Ringkasan Insight EDA

- Ketidakseimbangan kelas — kelas Hazardous (10%) jauh lebih sedikit dibanding Good (40%), sehingga evaluasi harus mengandalkan metrik per-kelas, bukan hanya akurasi keseluruhan.
- Inkonsistensi data ditemukan dan diperbaiki — 195 baris memiliki Humidity di atas batas fisik valid 100%; nilai tersebut di-cap, bukan dihapus.
- Distribusi fitur — Temperature dan Humidity mendekati normal; tidak diperlukan transformasi khusus.
- Outlier dipertahankan — outlier ringan pada Temperature/Humidity merepresentasikan cuaca ekstrem yang relevan untuk kelas Hazardous.
- Tidak ada multikolinearitas serius — korelasi antar fitur rendah-sedang, aman digunakan bersama pada Logistic Regression maupun Random Forest.
- Proximity dan Temperature paling diskriminatif — kedua fitur ini menunjukkan pemisahan paling jelas antar kelas, konsisten dengan hasil SHAP pada BAB VI.

BAB IV

BAB IV METODOLOGI DAN PIPELINE MACHINE LEARNING

4.1 Ringkasan Preprocessing

Aspek	Keputusan
Missing values	Tidak ditemukan — tidak diperlukan imputasi
Duplikat	Tidak ditemukan — tidak ada baris yang dihapus
Nilai tidak konsisten	Humidity di atas 100% (195 baris) di-cap pada 100% (BAB III.4)
Feature selection	5 kolom polutan dihapus untuk mencegah data leakage (BAB III.1)
Encoding	Tidak diperlukan encoding manual — scikit-learn dapat memproses label kelas berupa string secara langsung
Scaling	StandardScaler diperlukan untuk Logistic Regression (berbasis gradien, sensitif skala); tidak diperlukan untuk Random Forest (berbasis pohon, invariant terhadap skala). Scaler di-fit hanya pada data training untuk mencegah data leakage.

Tabel 5 Ringkasan Preprocessing

4.2 Strategi Data Splitting


Data dibagi menjadi tiga bagian: 70% training, 15% validation, dan 15% test, menggunakan stratified sampling agar proporsi kelas tetap terjaga pada setiap subset. Pembagian tiga arah ini (bukan hanya train/test) dipilih agar proses tuning dan pemilihan model tidak pernah menyentuh data test, sehingga hasil evaluasi akhir benar-benar mencerminkan performa pada data yang belum pernah dilihat sama sekali.

Subset	Jumlah Data	Persentase	Fungsi
Training	3.499	70,0%	Melatih model dan menjalankan hyperparameter tuning (GridSearchCV)
Validation	751	15,0%	Mengecek kewajaran model hasil tuning sebelum memutuskan model final

Subset	Jumlah Data	Persentase	Fungsi
Test	750	15,0%	Disentuh hanya sekali, untuk melaporkan performa akhir yang tidak bias

Tabel 6 Strategi Data Splitting (Train/Val/Test)

4.3 Gambaran Umum Pipeline End-to-End



Gambar 3 Diagram Alur Pipeline Machine Learning

Pipeline dirancang secara bertahap dan disiplin dalam menjaga data test tetap “murni” (tidak pernah digunakan untuk keputusan apa pun sebelum evaluasi akhir). Baseline model dilatih dengan hyperparameter default lebih dulu sebagai titik acuan, kemudian dibandingkan dengan versi hasil tuning pada validation set. Setelah model terbaik dipilih melalui validasi statistik (10-Fold CV dan Paired T-Test) pada gabungan data train+validation, model final dilatih ulang pada seluruh data train+validation, lalu dievaluasi tepat satu kali pada test set yang belum pernah tersentuh sama sekali.

Pendekatan ini — memisahkan proses tuning/pemilihan model dari evaluasi akhir — merupakan praktik standar untuk menghasilkan estimasi performa yang benar-benar tidak bias, dan menghindari risiko “mengintip” data test secara tidak sengaja selama proses eksperimen.

BAB V

BAB V PEMODELAN, TUNING, DAN VALIDASI STATISTIK

5.1 Baseline Model (Hyperparameter Default)

Dua model dilatih terlebih dahulu dengan hyperparameter default sebagai baseline, dievaluasi pada validation set:

Model	Akurasi Validation (Baseline)
Logistic Regression (default, C=1, StandardScaler)	81,89%
Random Forest (default, n_estimators=100)	87,08%

Tabel 7 Hasil Baseline Model (Validation Set)

5.2 Hyperparameter Tuning (GridSearchCV)

Kedua model di-tuning menggunakan GridSearchCV dengan 5-Fold Cross Validation, dijalankan hanya pada training set (validation dan test set tidak pernah digunakan untuk tuning).

Model	Parameter Grid	Best Params	CV Acc (Train)
Logistic Regression	C: [0.01, 0.1, 1, 10, 100], solver: [lbfgs]	C=1, solver=lbfgs	81,77%
Random Forest	n_estimators: [100,200,300], max_depth: [None,10,20], min_samples_split: [2,5], min_samples_leaf: [1,2]	n_estimators=300, max_depth=20, min_samples_split=5, min_samples_leaf=1	87,88%

Tabel 8 Grid Hyperparameter dan Hasil Tuning

Setelah tuning, kedua model kembali dievaluasi pada validation set untuk memastikan hasil tuning benar-benar memberikan peningkatan dibanding baseline: Logistic Regression tetap pada 81,89% (parameter default C=1 ternyata sudah optimal), sedangkan Random Forest meningkat dari 87,08% menjadi 87,22%.

5.3 Model Selection: 10-Fold Stratified Cross Validation dan Paired T-Test

Untuk memutuskan model terbaik secara lebih rigor dibandingkan perbandingan satu kali pada validation set, dilakukan 10-Fold Stratified Cross Validation dan Paired T-Test ($\alpha = 0,05$) pada gabungan data train+validation (test set tetap tidak tersentuh).

Model	Rata-rata Akurasi 10-Fold CV
Logistic Regression	81,65%
Random Forest	87,11%

Tabel 9 Hasil 10-Fold Cross Validation dan Paired T-Test

Hasil Paired T-Test menunjukkan t-statistic = 9,11 dengan p-value $\approx 0,000008$ (jauh lebih kecil dari $\alpha = 0,05$). Dengan demikian, keunggulan Random Forest dibandingkan Logistic Regression terbukti signifikan secara statistik, bukan sekadar kebetulan dari satu kali pembagian data. Random Forest secara konsisten mengungguli Logistic Regression pada seluruh 10 fold pengujian, sehingga dipilih sebagai model final untuk deployment dan interpretasi lebih lanjut.

5.4 Karakteristik Kedua Algoritma

Aspek	Logistic Regression	Random Forest
Cara kerja	Memodelkan probabilitas kelas melalui fungsi softmax, mempelajari koefisien bobot tiap fitur	Ensemble dari banyak Decision Tree, prediksi akhir melalui voting mayoritas
Kelebihan	Cepat, sangat mudah diinterpretasikan melalui koefisien	Menangkap hubungan non-linear, robust terhadap outlier, punya feature importance
Kekurangan	Hanya menangkap hubungan linear antar fitur	Lebih lambat, model relatif black-box dibanding regresi linear
Peran	Baseline pembanding	Model utama / final model

Tabel 10 Karakteristik Logistic Regression dan Random Forest

BAB VI

BAB VI HASIL EVALUASI DAN INTERPRETASI MODEL

6.1 Evaluasi Akhir pada Test Set (Data yang Belum Pernah Dilihat)

Random Forest dengan hyperparameter terbaik dilatih ulang pada gabungan data train+validation, lalu dievaluasi tepat satu kali pada test set (750 data) yang sepenuhnya belum pernah digunakan pada tahap mana pun sebelumnya — sehingga hasil berikut merupakan estimasi performa yang benar-benar tidak bias.

Model	Akurasi Test	Macro F1-Score	Macro ROC-AUC (OvR)
Logistic Regression (final)	80,27%	0,751	0,945
Random Forest (final)	89,20%	0,855	0,973

Tabel 11 Perbandingan Ringkasan Performa Akhir

Kedua metrik kesuksesan yang ditetapkan pada BAB I (macro F1-Score $> 0,80$ dan ROC-AUC $> 0,90$) berhasil tercapai oleh model Random Forest (F1 = 0,855; ROC-AUC = 0,973), sedangkan Logistic Regression tidak mencapai target F1-Score (0,751).

6.2 Classification Report per Kelas


Kelas	Precision	Recall	F1-Score	Support
Good	0,971	0,993	0,982	300
Moderate	0,868	0,907	0,887	225
Poor	0,791	0,733	0,761	150
Hazardous	0,826	0,760	0,792	75

Tabel 12 Classification Report Final — Random Forest (Test Set)

Kelas	Precision	Recall	F1-Score	Support
Good	0,922	0,980	0,950	300
Moderate	0,786	0,751	0,768	225
Poor	0,607	0,607	0,607	150
Hazardous	0,727	0,640	0,681	75

Tabel 13 Classification Report Final — Logistic Regression (Test Set)

Random Forest unggul konsisten pada seluruh kelas. Peningkatan paling signifikan terlihat pada kelas Poor (F1 dari 0,607 menjadi 0,761) dan Hazardous (F1 dari 0,681 menjadi 0,792) — dua kelas yang paling menantang karena posisinya berdekatan secara ordinal dengan kelas tetangganya serta jumlah sampel yang lebih sedikit.




Gambar 4 Confusion Matrix — Final Random Forest (Test Set)


Confusion matrix menunjukkan kesalahan klasifikasi Random Forest sebagian besar terjadi antar kelas yang berdekatan secara ordinal: 17 sampel Hazardous terprediksi sebagai Poor, dan 28 sampel Poor terprediksi sebagai Hazardous. Pola ini wajar mengingat kategori kualitas udara pada dasarnya bersifat bertingkat (ordinal), sehingga kesalahan cenderung terjadi pada kelas yang berdekatan, bukan antar kelas yang jauh berbeda seperti Good dan Hazardous (kesalahan antar keduanya nyaris tidak ada).

6.3 Interpretasi Model: Feature Importance dan SHAP

Untuk memahami faktor apa yang paling memengaruhi prediksi model, dilakukan dua pendekatan interpretasi: `feature_importances_` bawaan Random Forest, dan SHAP (SHapley Additive exPlanations) — pendekatan yang lebih rigor secara teori permainan (game-theoretic) dan memberikan kontribusi fitur per prediksi individual, bukan hanya skor global.



Gambar 5 Feature Importance — Random Forest



Gambar 6 SHAP Summary Plot per Kelas

Peringkat	Fitur	Feature Importance (RF)	Mean SHAP value
1	Proximity_to_Industrial_Areas	0,538 (53,8%)	0,200
2	Temperature	0,208 (20,8%)	0,072
3	Population_Density	0,138 (13,8%)	0,045
4	Humidity	0,116 (11,6%)	0,036

Tabel 14 Feature Importance & SHAP Ranking

Kedua metode interpretasi menghasilkan urutan peringkat fitur yang identik: Proximity_to_Industrial_Areas adalah faktor paling dominan (lebih dari separuh kontribusi total), diikuti oleh Temperature. Population_Density dan Humidity berkontribusi lebih kecil namun tetap relevan sebagai faktor pendukung. Temuan ini konsisten dengan pola yang ditemukan pada analisis EDA di BAB III.7, yang menunjukkan sampel Hazardous dan Poor cenderung berada lebih dekat ke kawasan industri dan memiliki suhu yang lebih tinggi.

6.4 Insight Bisnis

- Proximity_to_Industrial_Areas dan Temperature adalah dua prediktor paling kuat yang tersedia tanpa sensor polutan langsung — kedua fitur ini dapat menjadi prioritas dalam pengumpulan data jika sumber daya pemantauan terbatas.
- Wilayah yang lebih dekat dengan kawasan industri dan bersuhu lebih tinggi cenderung masuk kategori Poor atau Hazardous — pola ini dapat menjadi dasar prioritas pemantauan bagi pemerintah daerah.
- Model tetap perlu ditingkatkan khususnya untuk membedakan kelas Poor dan Hazardous, karena keduanya paling sering tertukar — pengumpulan data tambahan atau fitur baru pada wilayah dengan karakteristik ini dapat menjadi prioritas pengembangan selanjutnya.

6.5 Analisis Overfitting

Untuk memastikan model tidak overfitting, akurasi rata-rata 10-fold cross validation (87,11%) dibandingkan dengan akurasi test set akhir (89,20%). Selisih keduanya berada dalam rentang wajar dan bahkan performa test set sedikit lebih tinggi, mengindikasikan

model melakukan generalisasi dengan baik pada data yang belum pernah dilihat, tanpa indikasi overfitting yang signifikan.

BAB VII

BAB VII DEPLOYMENT STREAMLIT DASHBOARD

7.1 Platform dan Alasan Pemilihan

Model final beserta scaler diekspor ke format .pkl menggunakan joblib, kemudian dikemas ke dalam aplikasi web interaktif menggunakan Streamlit dan di-deploy secara publik melalui Streamlit Community Cloud. Streamlit dipilih karena memungkinkan pembuatan dashboard interaktif sepenuhnya menggunakan Python, tanpa memerlukan HTML/CSS/JavaScript terpisah, sehingga cocok untuk menyajikan solusi Machine Learning kepada pengguna non-teknis secara cepat.

Aplikasi telah berhasil di-deploy dan dapat diakses publik melalui tautan berikut:


 <https://air-quality-prediction-ml-15596.streamlit.app>

7.2 Struktur Halaman Aplikasi


Aplikasi terdiri atas enam halaman yang dapat diakses melalui sidebar navigasi, masing-masing memenuhi salah satu requirement wajib pada soal UAS (dashboard EDA, model demo, evaluasi model, interpretasi hasil, dan dokumentasi):

Halaman	Isi
 Beranda	Ringkasan proyek, problem statement, dan ringkasan dataset
 Dashboard EDA	Visualisasi interaktif distribusi kelas, distribusi fitur, korelasi antar fitur, dan pola fitur terhadap kelas target
 Model Demo	Form input interaktif (Temperature, Humidity, Proximity, Population Density) untuk mendapatkan prediksi kategori kualitas udara secara real-time beserta probabilitas tiap kelas
 Evaluasi Model	Akurasi, macro F1-Score, ROC-AUC, classification report, confusion matrix, dan kurva ROC yang dihitung langsung (live) dari test set
 Interpretasi & Insight	Grafik feature importance dan analisis SHAP on-demand, dilengkapi insight bisnis
 Dokumentasi	Deskripsi dataset, ringkasan metodologi, dan panduan penggunaan aplikasi

Tabel 15 Halaman pada Aplikasi Streamlit




Gambar 7 Halaman Beranda




Gambar 8 Halaman Dashboard




Gambar 9 Halaman Model Demo



Gambar 10 Halaman Evaluasi Model




Gambar 11 Halaman Interpretasi dan Insight



Gambar 12 Halaman Dokumentasi

7.3 Alur Inference: Input → Model → Output



Gambar 13 Diagram Alur Interface

Pada halaman Model Demo, pengguna memasukkan nilai keempat parameter meteorologi melalui form interaktif. Nilai tersebut kemudian diproses langsung oleh model Random Forest yang telah dimuat (di-cache agar tidak perlu reload setiap interaksi), menghasilkan kategori prediksi beserta distribusi probabilitas untuk keempat kelas, ditampilkan dalam bentuk kartu hasil dan grafik batang probabilitas.

7.4 Penanganan File pada Deployment

Karena Streamlit Community Cloud menjalankan aplikasi dengan direktori root repository sebagai working directory (bukan folder tempat app.py berada), salinan model, scaler, dan dataset turut disertakan langsung di dalam folder app/ agar aplikasi dapat menemukan file-file tersebut secara konsisten terlepas dari konteks eksekusinya. Path file di dalam app.py di-resolve secara relatif terhadap lokasi script itu sendiri untuk memastikan aplikasi tetap berjalan baik secara lokal maupun setelah di-deploy.

BAB VIII

BAB VIII DOKUMENTASI REPOSITORY, KESIMPULAN, DAN REKOMENDASI

8.1 Struktur Repository GitHub

Repository project ini bersifat publik dan disusun mengikuti struktur folder standar untuk proyek Machine Learning, memisahkan data, notebook eksperimen, model artifact, aplikasi deployment, dan laporan:

Folder / File	Fungsi
data/	Dataset mentah (updated_pollution_dataset.csv)
notebooks/air_quality_prediction.ipynb	Notebook lengkap — EDA, preprocessing, baseline, tuning, validasi statistik, evaluasi akhir, dan SHAP
models/	Model Random Forest final (rf_air_quality_model.pkl) dan StandardScaler (scaler.pkl)
app/	Aplikasi Streamlit (app.py), requirements.txt, serta salinan model/scaler/dataset untuk keperluan deployment
reports/	Laporan teknis proyek (dokumen ini, final_report.pdf)
requirements.txt	Daftar dependency tingkat proyek
README.md	Dokumentasi proyek — problem statement, metodologi, hasil, dan tautan live demo

Tabel 16 Struktur Repository GitHub

Repository dapat diakses secara publik melalui tautan berikut, dan mencakup seluruh kode, dataset, model, aplikasi, serta dokumentasi yang digunakan pada proyek ini:

 <https://github.com/sabrinaangel/air-quality-prediction-ML>

8.2 Kesimpulan

- Model Random Forest (setelah tuning) terbukti unggul secara konsisten dan signifikan secara statistik dibandingkan Logistic Regression, dengan akurasi 10-fold cross validation 87,11% berbanding 81,65% (Paired T-Test, $p \approx 0,000008 < 0,05$).
- Pada evaluasi akhir yang tidak bias (test set yang belum pernah dilihat), Random Forest mencapai akurasi 89,20%, macro F1-Score 0,855, dan ROC-AUC 0,973 — melampaui target metrik kesuksesan yang ditetapkan pada BAB I ($F1 > 0,80$ dan $ROC-AUC > 0,90$).
- Analisis feature importance dan SHAP secara konsisten menunjukkan Proximity_to_Industrial_Areas (53,8%) dan Temperature (20,8%) sebagai dua faktor paling dominan dalam menentukan kualitas udara, sesuai dengan hipotesis awal penelitian.
- Proses EDA berhasil menemukan dan menangani inkonsistensi data (195 baris Humidity di atas 100%) yang tidak akan terdeteksi oleh pengecekan missing value/duplikat standar.
- Model dan scaler berhasil di-deploy ke dalam aplikasi Streamlit interaktif yang telah live di <https://air-quality-prediction-ml-15596.streamlit.app>, mencakup dashboard EDA, demo prediksi real-time, evaluasi model, dan interpretasi hasil.
- Tantangan utama tersisa pada klasifikasi kelas Poor dan Hazardous, yang paling sering tertukar karena posisinya berdekatan secara ordinal dan jumlah sampelnya lebih sedikit dibanding kelas Good/Moderate.

8.3 Rekomendasi Pengembangan Selanjutnya

- Menambahkan data historis multi-tahun atau dari wilayah geografis lain untuk menguji generalisasi model di luar konteks data pelatihan saat ini.
- Mengeksplorasi teknik penanganan class imbalance tambahan (misalnya SMOTE atau `class_weight='balanced'`) khusus untuk meningkatkan recall kelas Hazardous lebih lanjut.
- Mempertimbangkan pendekatan ordinal classification, mengingat kategori kualitas udara pada dasarnya bersifat bertingkat, untuk mengurangi kesalahan klasifikasi antar kelas yang berdekatan (Poor vs Hazardous).

- Menambahkan fitur cuaca tambahan seperti kecepatan angin dan tekanan udara (jika tersedia) untuk memperkaya sinyal prediktif tanpa perlu data polutan langsung.
- Menyiapkan mekanisme monitoring model di production (model drift monitoring) mengingat pola cuaca dan polusi dapat berubah seiring waktu (concept drift).

DAFTAR PUSTAKA

- Breiman, L. (2001). Random Forests. *Machine Learning*, 45(1), 5–32.
- Lundberg, S. M., & Lee, S. I. (2017). A Unified Approach to Interpreting Model Predictions. *Advances in Neural Information Processing Systems (NeurIPS)*.
- Matin, M. (2023). Air Quality and Pollution Assessment [Dataset]. Kaggle. <https://www.kaggle.com/datasets/mujtabamatin/air-quality-and-pollution-assessment>
- Pedregosa, F., et al. (2011). Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research (JMLR)*, 12, 2825–2830.
- Sabrina Angel. (2026). air-quality-prediction-ML [Repositori GitHub]. Diakses dari <https://github.com/sabrinaangel/air-quality-prediction-ML>
- Streamlit Inc. (2024). Streamlit Documentation. Diakses dari <https://docs.streamlit.io/>
- World Health Organization. (2021). WHO Global Air Quality Guidelines. WHO Press.